Séquençage rationalisé 3' mRNA-seq

Plateforme de transcriptomique GeT-TRiX Gaëlle Payros et Yannick Lippi

> **Biopuces 9 Octobre 2025**









La plateforme GeT-TRIX

Services intégrés d'analyses transcriptomiques

- Une plateforme dédiée aux études transcriptomiques
 - Mise à disposition d'équipements
 - Prestations « clés en main »
 - Collaboration R&D
 - Partenariat sur contrat de recherche
- Une expertise technologique
 - Analyses transcriptomiques
 - RNA-seq
 - **Microarray**
 - Analyses Bioinformatiques/Biostatistiques

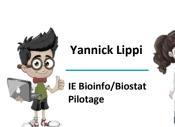
(§) Genotoul **Genotoul** Réseau de 12 Plateforme multi-sites plateformes toulousaines d'Hébergemen Toxalim INRAE Bordeaux

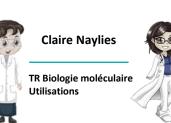
Clermont

Auzeville

Environnement

Evry





Gaëlle Payros

IE Biologie moléculaire **R&D NGS**

INRAO

QuantSeq 3' mRNA-seq

- Contexte
- Principe
- Différence avec RNA-seq « classique » ?

Contexte



Proposer un nouveau service d'étude du transcriptome, **adapté** pour l'expression génique différentielle sans *a priori* par séquençage des ARN messagers :

• Séquençage rationalisé des queues 3' des transcrits et non des transcrits pleine longueur



Service abordable en termes de coûts/masse de données (séquençage <a>□)



Applicable sur un grand nombre d'individus : multiplexage



• Performant sur sang total via l'utilisation de « bloqueurs de globine » (disponible pour humain et cochon)



• Applicable à partir de matériel faible qualité

Contexte







Proposer un nouveau service d'étude du transcriptome, **adapté** pour l'expression génique différentielle sans *a priori* par séquençage des ARN messagers :

• Séquençage rationalisé des queues 3' des transcrits et non des transcrits pleine longueur



Service abordable en termes de coûts/masse de données (séquençage <a>□)



Applicable sur un grand nombre d'individus : multiplexage



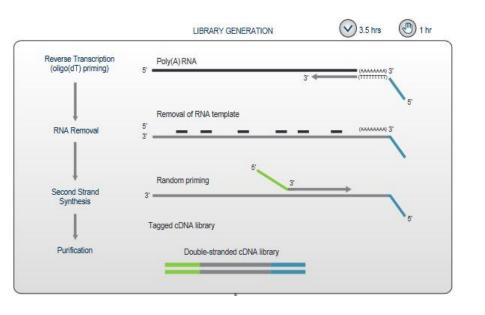
• Performant sur sang total via l'utilisation de « bloqueurs de globine » (disponible pour humain et cochon)



• Applicable à partir de matériel faible qualité

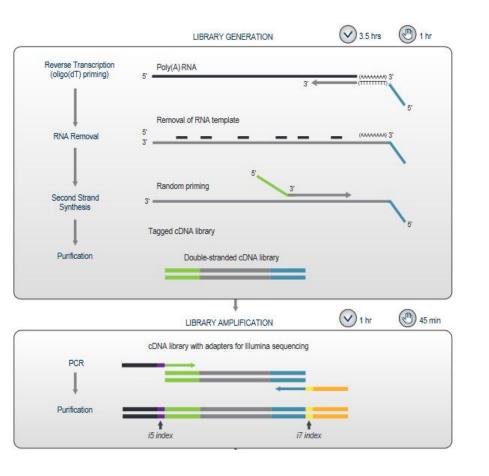
Financement Carnot F2E en collaboration avec GenPhySE. **Projet ATraGESeqR** : **A**nalyse **Tra**nscriptomique à **G**rande **E**chelle par **Séq**uençage **R**ationalisé

QuantSeq 3' mRNA-Seq V2 Library Prep Kit with UDI_Lexogen



- 1) Reverse Transcription : Synthèse du premier brin cDNA : oligo (dT) sur les queues Poly(A) des ARN.
- 2) Elimination de l'ARN
- 3) Synthèse du deuxième brin : Random primer : un fragment par transcrit
- 4) Purification sur billes

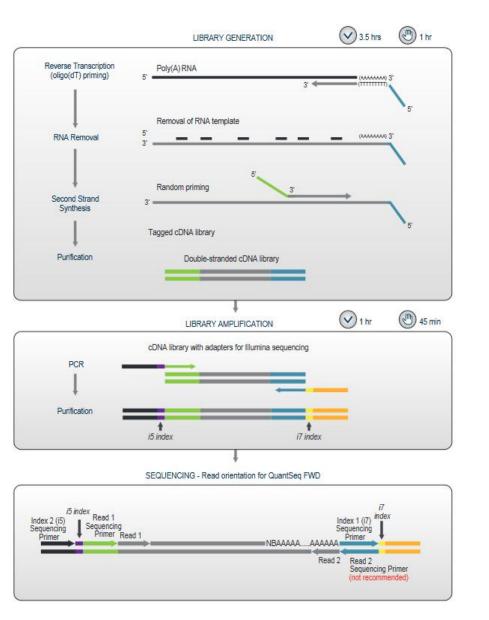
QuantSeq 3' mRNA-Seq V2 Library Prep Kit with UDI_Lexogen



- 1) Reverse Transcription : Synthèse du premier brin cDNA : oligo (dT) sur les queues Poly(A) des ARN.
- 2) Elimination de l'ARN
- 3) Synthèse du deuxième brin : Random primer : un fragment par transcrit
- 4) Purification sur billes

- 5) Amplification par PCR (+ ajout des index)
- 6) Purification finale sur billes
- 7) Contrôle qualité des librairies + Pool

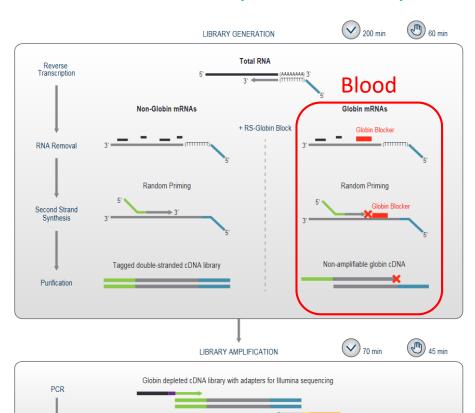
QuantSeq 3' mRNA-Seq V2 Library Prep Kit with UDI_Lexogen



- 1) Reverse Transcription : Synthèse du premier brin cDNA : oligo (dT) sur les queues Poly(A) des ARN.
- 2) Elimination de l'ARN
- 3) Synthèse du deuxième brin : Random primer : un fragment par transcrit
- 4) Purification sur billes

- 5) Amplification par PCR (+ ajout des index)
- 6) Purification finale sur billes
- 7) Contrôle qualité des librairies + Pool
- 8) Séquençage : Taille optimisée pour des longueurs de lectures courtes : SR50 100 pb. 3-5 M /lectures par échantillon

QuantSeq 3' mRNA-Seq V2 Library Prep Kit with UDI_Lexogen



SEQUENCING - Read orientation for QuantSeq FWD

i7 index

i5 index (optional)

Purification

Index 2 (i5)
Sequencing
Primer
Read 1
Sequencing
Primer
Read 1

Read 2
Read 2
Sequencing Primer
Read 2
Sequencing Primer
(not recommended)

- 1) Reverse Transcription : Synthèse du premier brin cDNA : oligo (dT) sur les queues Poly(A) des ARN.
- 2) Elimination de l'ARN + RS-Globin Block : empêche la génération de fragments à partir d'ARNm de globine, en se liant à l'ADNc et en empêchant la formation d'ADNc double brin
- 3) Synthèse du deuxième brin : Random primer : un fragment par transcrit
- 4) Purification sur billes
- 5) Amplification par PCR (+ ajout des index)
- 6) Purification finale sur billes
- 7) Contrôle qualité des librairies + Pool
- 8) Séquençage : Taille optimisée pour des longueurs de lectures courtes : SR50 100 pb. 3-5 M /lectures par échantillon



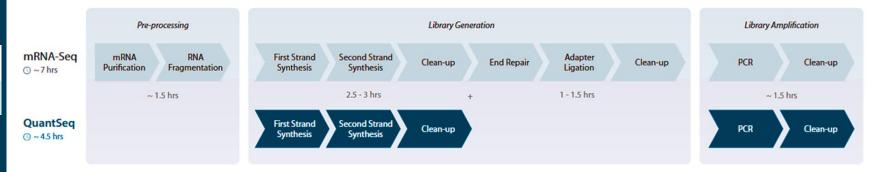
3' mRNA-seq

RNA-seq « classique »

Pas de fragmentation des ARN messagers

Fragmentation des ARN messagers







3' mRNA-seq

RNA-seq « classique »

Pas de fragmentation des ARN messagers



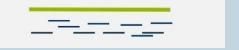




Une seule lecture par transcrit



Plusieurs lectures par transcrit





3' mRNA-seq

RNA-seq « classique »

Pas de fragmentation des ARN messagers

Fragmentation des ARN messagers





Une seule lecture par transcrit

Plusieurs lectures par transcrit



Quantifier l'expression des gènes codants Analyser l'expression différentielle des gènes (DGE)



3' mRNA-seq

RNA-seq « classique »

Pas de fragmentation des ARN messagers

Fragmentation des ARN messagers

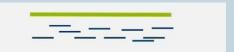




Une seule lecture par transcrit



Plusieurs lectures par transcrit



Quantifier l'expression des gènes codants Analyser l'expression différentielle des gènes (DGE)

- Meilleure détection des petits transcrits Limitations:
- Découverte de nouveaux transcrits ou variants d'épissage
 - Détecter les isoformes proches de l'extrémité 5'
- Analyser des transcrits complets, des gènes de fusion
- Transcriptome entier
- Découverte de nouveaux transcrits ou variants d'épissage
- Identifier les isoformes connues et nouvelles
- Détecter les fusions de gènes

3' mRNA-seq

RNA-seq « classique »

Pas de fragmentation des ARN messagers

Fragmentation des ARN messagers





Une seule lecture par transcrit



Plusieurs lectures par transcrit



Quantifier l'expression des gènes codants Analyser l'expression différentielle des gènes (DGE)

- Meilleure détection des petits transcrits Limitations:
- Découverte de nouveaux transcrits ou variants d'épissage
 - Détecter les isoformes proches de l'extrémité 5'
- Analyser des transcrits complets, des gènes de fusion
- Transcriptome entier
- Découverte de nouveaux transcrits ou variants d'épissage
- Identifier les isoformes connues et nouvelles
- Détecter les fusions de gènes

Profondeur de séquençage : 5M reads/éch

Séquençage rationalisé de l'extrémité 3' des ARN polyadénylés

Profondeur de séquençage : 30M à 100 M reads/éch

Séquençage sur toute la longueur du transcrit



INRAO

QuantSeq 3' mRNA-seq sur tissus

- Conditions expérimentales validées
- Analyse comparative avec des données RNA-seq « classique »
- Identification de la profondeur de séquençage optimale

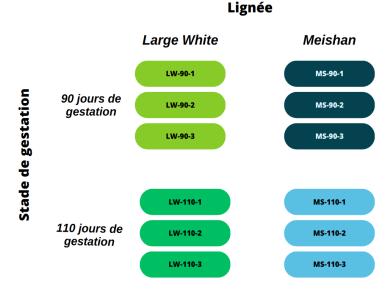


Conditions expérimentales

- 12 échantillons tissulaires endomètre de truie (cohorte PORCINET, GenpHySE) :
 - o 2 génotypes:
 - Large White LW
 - Meishan MS
 - 2 stades de gestations (90-110j)
- Input: 500 ng ARN total
- Séquençage 1 X 75 cycles



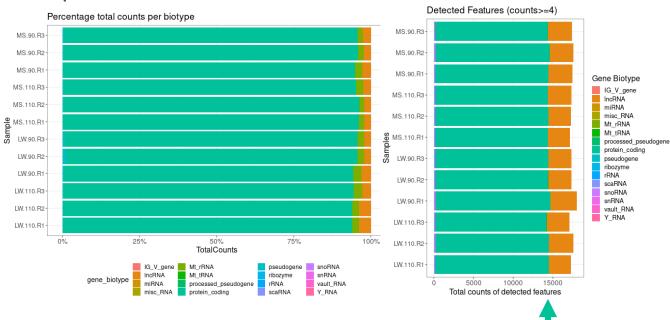
Environ 30M reads par échantillon (pour voir l'impact de la profondeur)





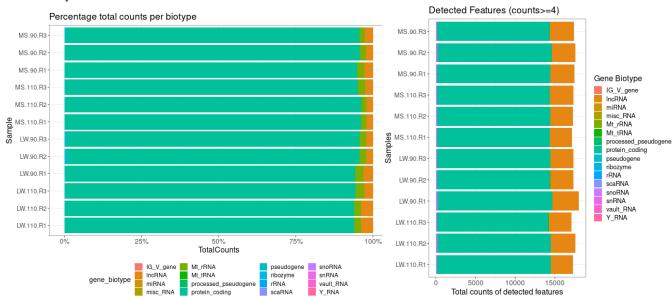
Résultats QuantSeq

- La majorité des gènes exprimés codent pour des protéines (environ 14 000).
- Une faible quantité, codent pour des longs ARN non codants et des ARN ribosomiques mitochondriaux (<5%).



Résultats QuantSeq

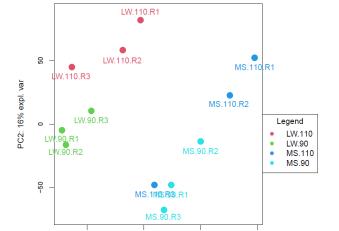
- La majorité des gènes exprimés codent pour des protéines (environ 14 000).
- Une faible quantité, codent pour des longs ARN non codants et des ARN ribosomiques mitochondriaux (<5%).



-50

• La variance entre les échantillons s'expliquent principalement :

- par le génotype de la mère LW vs MS
- puis le temps de gestation 90 vs 110 j



PC1: 21% expl. vai

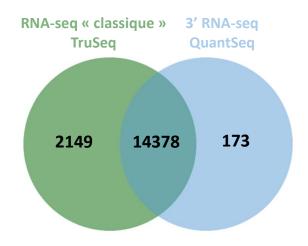
PlotIndiv





Analyse comparative avec les données RNA-seq « classiques » (TruSeq)

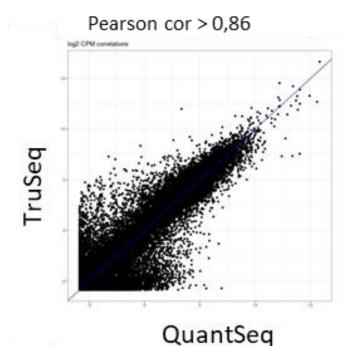
- 87% des gènes codants pour des protéines identifiés en RNA-seq « classique » sont identifiés avec le 3' RNA-seq.
 - **→ 14 378 gènes**



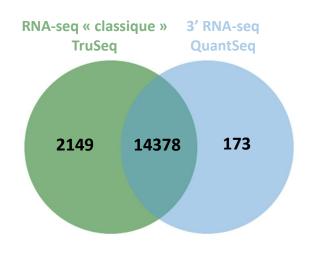


Analyse comparative avec les données RNA-seq « classiques » (TruSeq)

- 87% des gènes codants pour des protéines identifiés en RNA-seq « classique » sont identifiés avec le 3' RNA-seq.
 - → **14 378** gènes



Bonne corrélation des données





14378

RNA-seq « classique »

TruSeq

2149



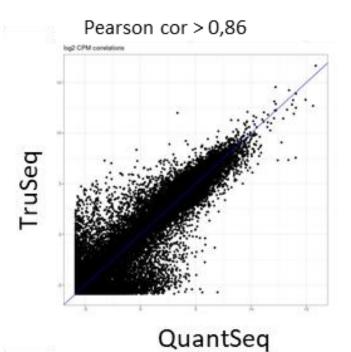
3' RNA-sea

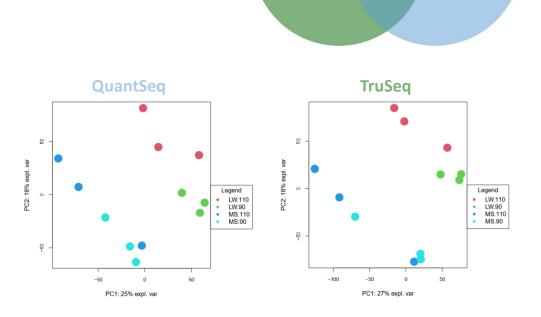
QuantSeq

173

Analyse comparative avec les données RNA-seq « classiques » (TruSeq)

- 87% des gènes codants pour des protéines identifiés en RNA-seq « classique » sont identifiés avec le 3' RNA-seq.
 - → 14 378 gènes





Bonne corrélation des données

→ Structuration similaire des données

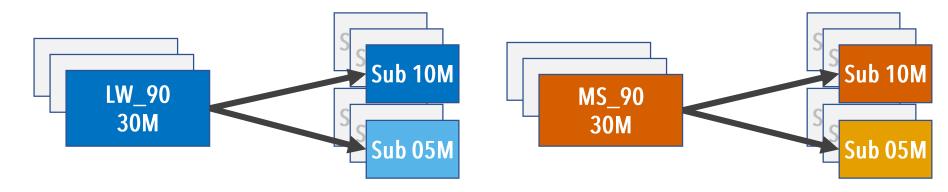
→ Le QuantSeq donne des données comparables au TruSeq



Identification de la profondeur de séquençage optimale

Comparer les résultats obtenus avec 05M et 10M de lectures

- Etape 1 : Définir le nombre de répétitions minimal et suffisant pour représenter la diversité des données initiales
 → 12 répétitions
- Etape 2 : Sous-échantillonnage : 12 tirages aléatoires des lectures obtenues pour chaque individu à partir des 30M de lectures
 - → pour la profondeur à **05M**
 - → pour la profondeur à 10M



Etape 3 : Exploration et comparaison des données à 05M et 10M de lectures



Données filtrées sur les Moyennes des 12 itérations Sous-échantillonnage 05 millions de lectures 10 millions de lectures

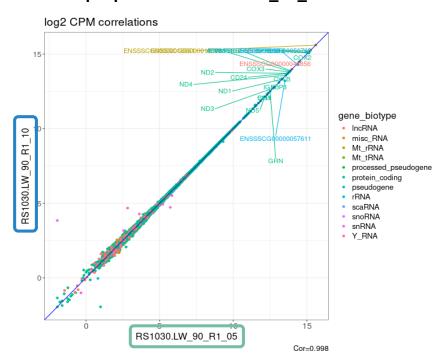




Identification de la profondeur de séquençage optimale

- Très bonnes corrélations 05M vs 10M, même pour les très faibles comptages!
- Pas de gènes spécifiquement détectés selon 05M ou 10M

Exemple pour un individu LW_90_R1





Données filtrées sur les Moyennes des 12 itérations Sous-échantillonnage 05 millions de lectures 10 millions de lectures

Heatmap des DEG 05M et 10M

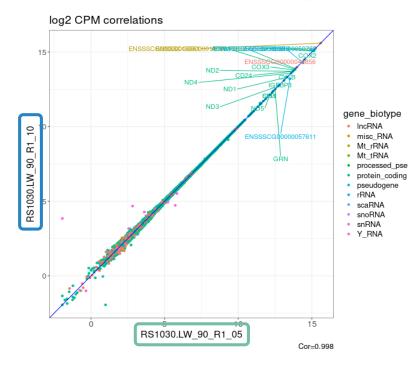


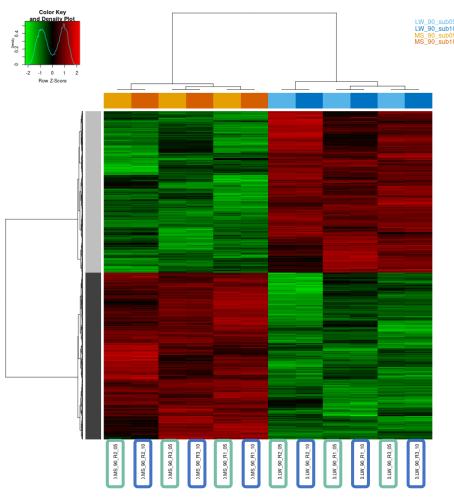


Identification de la profondeur de séquençage optimale

- Très bonnes corrélations 05M vs 10M, même pour les très faibles comptages!
- Pas de gènes spécifiquement détectés selon 05M ou 10M
- Réponses similaires à 05M et 10M

Exemple pour un individu LW_90_R1





→ Validation de la capacité à détecter des gènes et des différences avec 05M de lectures brutes

INRAO

> QuantSeq 3' mRNA-seq sur sang total

- Conditions expérimentales validées
- Analyse comparative : efficacité du blocage des globines
- Analyse comparative avec des données MACE 3' RNA-seq et Microarray



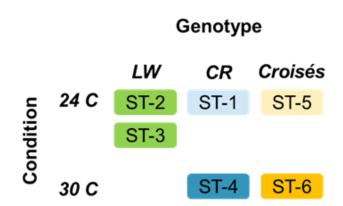


Conditions expérimentales

- 6 échantillons **sang total de cochon** (cohorte PigChange, GenPhySE) :
 - 3 génotypes (Large White, Creole, Croisés)
 - 2 conditions (Température 24C et 30C)
- Input: 200 ng ARN total
- Utilisation RS-Globin Block, Sus scrofa: empêche la génération de fragments de librairies à partir d'ARNm de globine
- Séquençage 1 X 150 cycles



→ 75 cycles suffit perte de qualité après









Analyse comparative : Efficacité du blocage des globulines

Quant Seq 3' RNA-Seq

+ Bloqueur globine

15 156 gènes détectés

MACE 3' RNA-Seq

8 812 gènes détectés

Micro Array

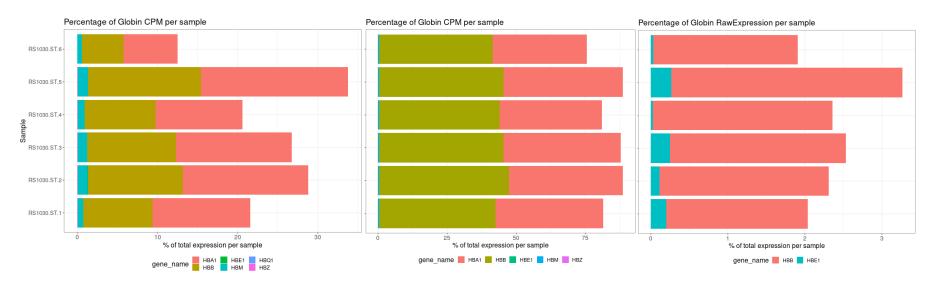
5 771 gènes détectés





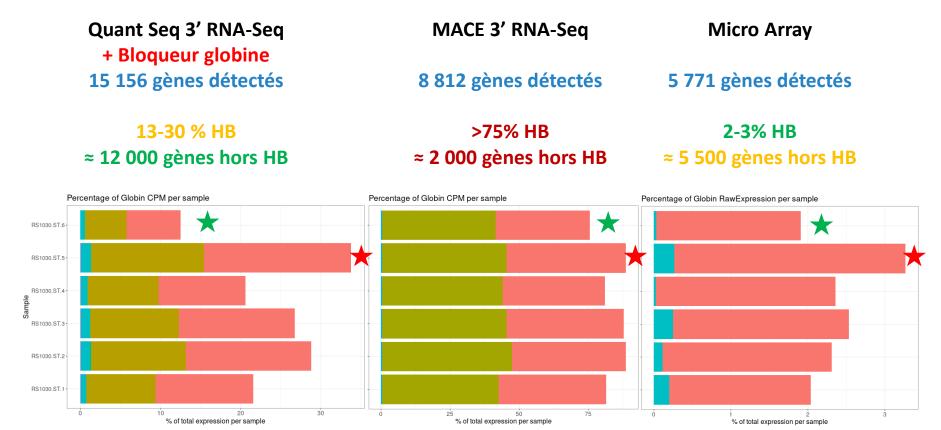
Analyse comparative : Efficacité du blocage des globulines

Quant Seq 3' RNA-Seq + Bloqueur globine	MACE 3' RNA-Seq	Micro Array
15 156 gènes détectés	8 812 gènes détectés	5 771 gènes détectés
13-30 % HB ≈ 12 000 gènes hors HB	>75% HB ≈ 2 000 gènes hors HB	2-3% HB ≈ 5 500 gènes hors HB





Analyse comparative : Efficacité du blocage des globulines



- Différences entre échantillons conservées entre les 3 technologies :
 ST5 ★ le plus « contaminé » et ST6 ★ le moins en hémoglobine
 - → Validation de l'efficacité du bloqueur de globine, plus de gènes exploitables

gene name HBA1 HBB HBE1 HBM HBZ

gene name HBB HBE1

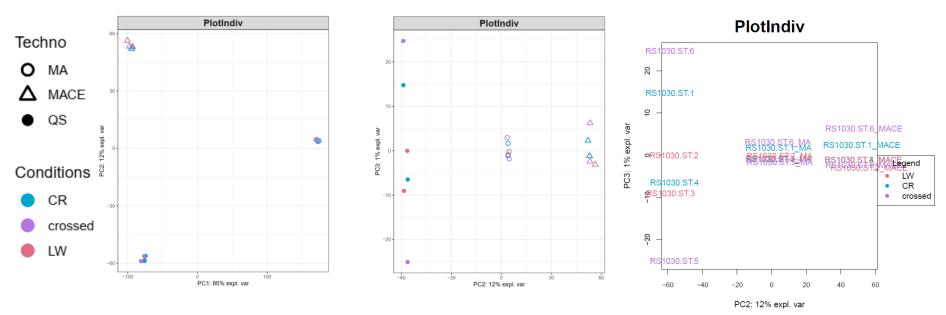
>

Mise au point sur sang total





Analyse comparative avec des données MACE 3' RNA-Seq et Micro array



PC1 (axe horizontal) = Microarray o vs QuantSeq • et MACE Δ PC2 (axe vertical) = QuantSeq vs MACE PC3 (Axe vertical) = individus intra techno

 La technologie structure les données (PC1 et PC2) mais des effets échantillons sont communs aux 3 technologies (PC3)

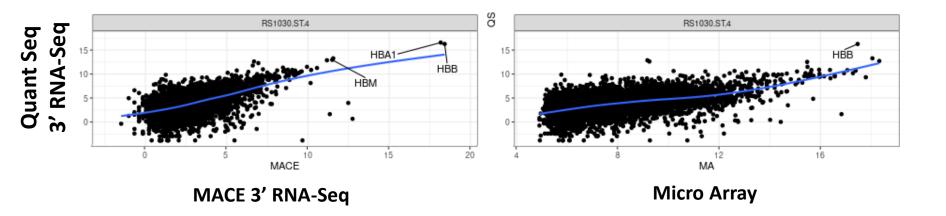
>

Mise au point sur sang total





Analyse comparative avec des données MACE 3' RNA-Seq et Micro array



- Corrélations significatives entre les technologies (R ~0,5)
- Pas de gros biais de distribution
- HBB/HBA les plus exprimés quelle que soit la techno

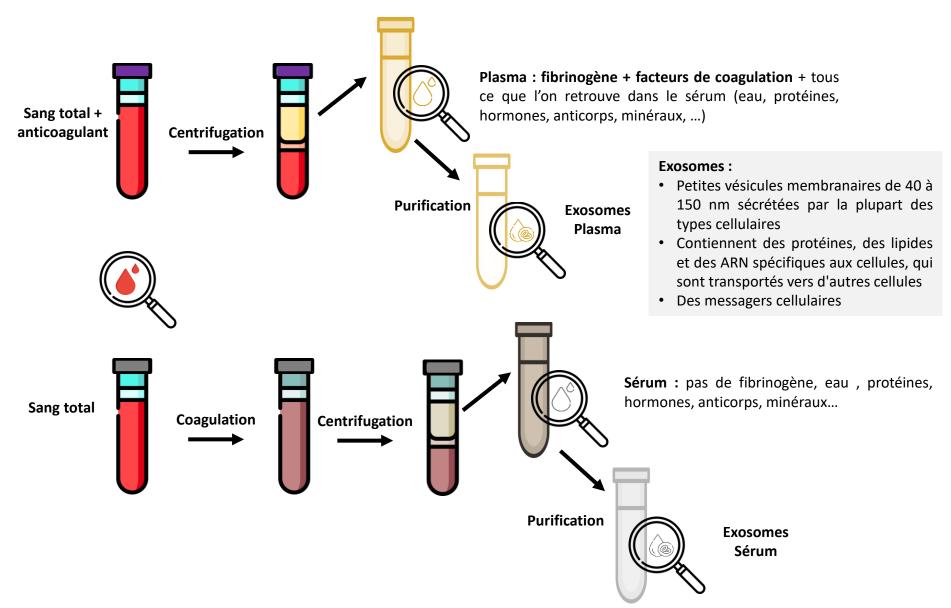
→ Quant Seq sur sang donne des résultats exploitables et corrélés aux autres technologies MACE 3' RNA-Seq et Micro array

INRAO

- ➤ QuantSeq 3' mRNA-seq sur différents compartiments sanguins : sang total, sérum, plasma, exosomes
 - Conditions expérimentales validées
 - Résultats : exploration biostatistique

> Différents compartiments sanguins





Différents compartiments sanguins





Plasma







- Bio fluide facile à obtenir
- Prélèvement non létal
- Suivi longitudinal : Possibilité mesures répétées
- Mise en évidence de **biomarqueurs**.....



Sérum





Différents compartiments sanguins





Conditions expérimentales

- 4 jeunes truies de 5 semaines (Duroc DanBred X Hybride DanBred) (BioToMyc, P.Pinton)
- 20 échantillons
- Différentes extractions ARN (GenPhySE) et préparations des librairies



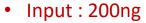
Sang total

Extraction ARN PAXGENE



Sérum Plasma





- Nb de cycle PCR : 17
- **Protocole Standard**
- **RS-Globin Block**
- Séquençage 1 X 76 cycles





- Nb de cycle PCR : 21
- Protocole low quality / input





Exosomes Exosomes Sérum Plasma

Purification des exosomes Extraction ARN Exosomes Norgen

- Input : 5µl variable
- Nb de cycle PCR: 26
- Protocole low quality / input

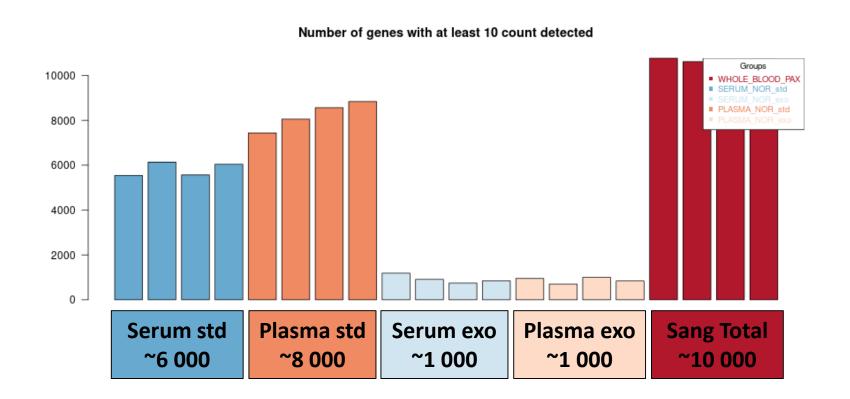


Différents compartiments sanguins





Résultats : Exploration biostatistique : Nombre de gènes

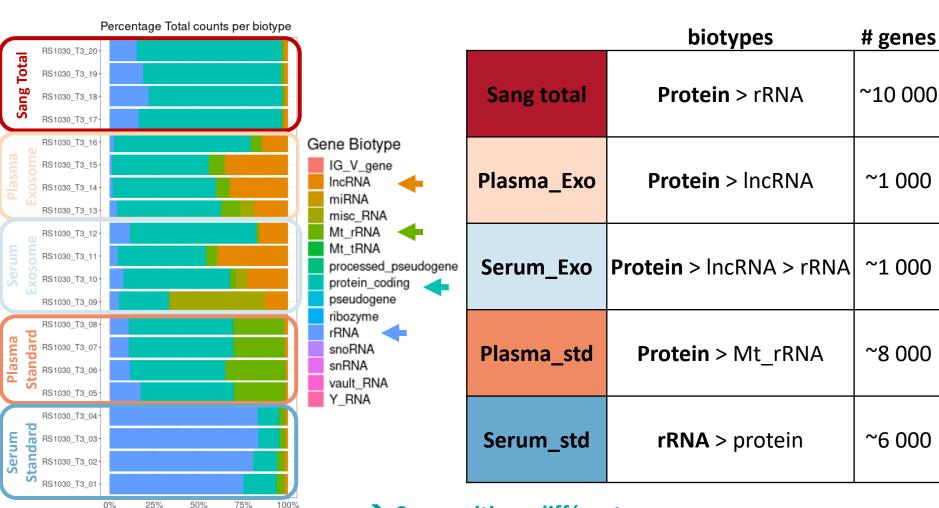


→ En fonction du compartiment, le nombre de gènes détectés varie mais reste reproductible pour les quatre individus





Résultats: Exploration biostatistique: Composition



Compositions différentes :

Protein coding majoritaires dans le Sang total et le Plasma mais pas dans le Serum

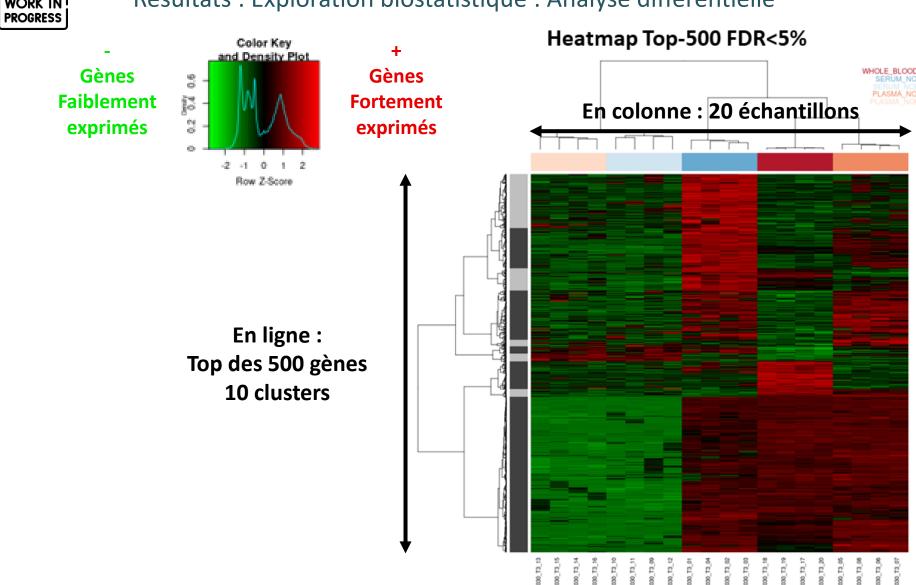
37







Résultats : Exploration biostatistique : Analyse différentielle



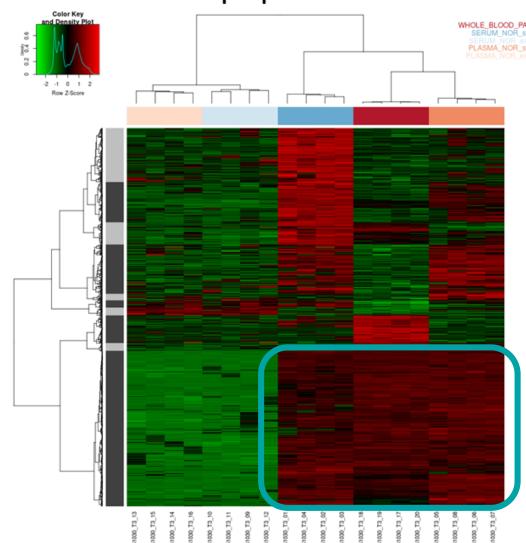






Résultats : Exploration biostatistique : Analyse différentielle

Heatmap Top-500 FDR<5%



 De nombreux transcrits codant des protéines sont exprimés plus fortement dans le Sang Total, le Plasma et le Serum



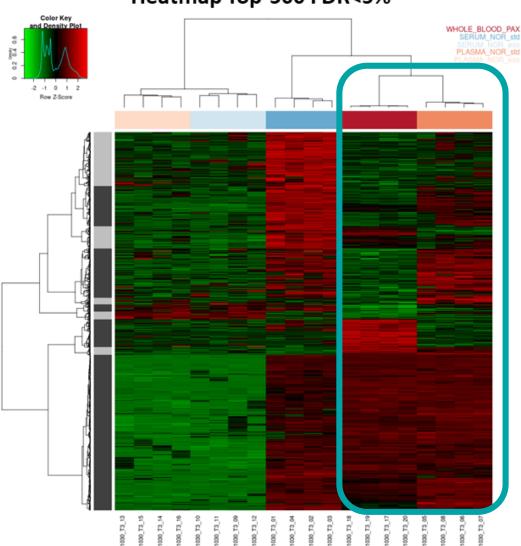




Résultats : Exploration biostatistique : Analyse différentielle

Heatmap Top-500 FDR<5%

 Le Plasma donne des profils d'expressions les plus proches du Sang Total comme on le voit avec la distance









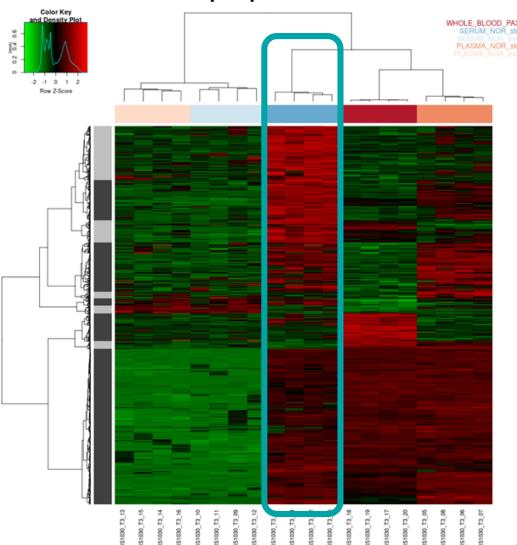
Résultats : Exploration biostatistique : Analyse différentielle

Le Plasma donne des profils d'expressions les plus proches du

Sang Total comme on le voit avec la distance

 Le Serum présente des profils plus spécifiques (notamment IncRNA) par rapport au Sang Total ou au Plasma

Heatmap Top-500 FDR<5%



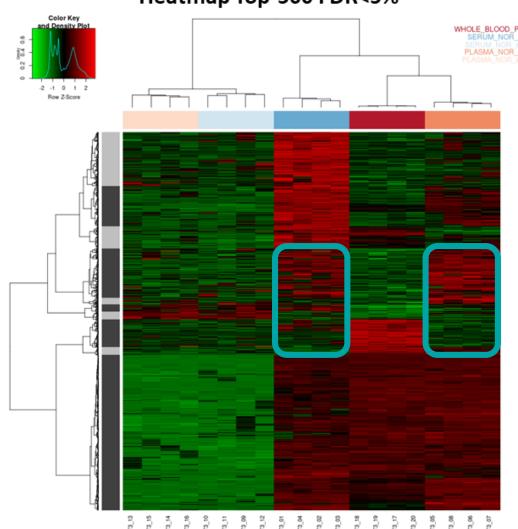






Résultats : Exploration biostatistique : Analyse différentielle

Heatmap Top-500 FDR<5%



 Des profils d'expression sont spécifiques et communs pour le Plasma et le Serum (proteines + IncRNA + snRNA)

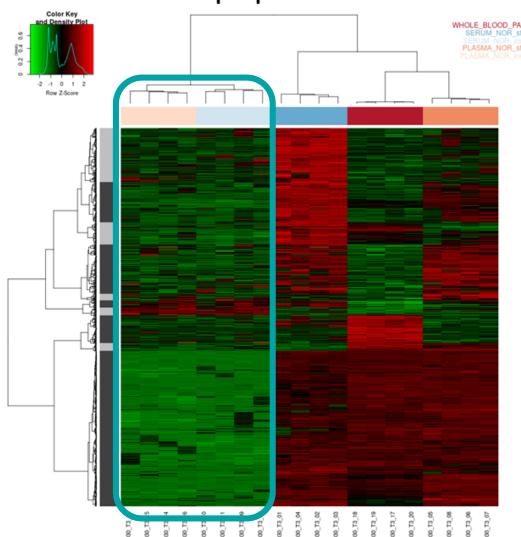






Résultats : Exploration biostatistique : Analyse différentielle

Heatmap Top-500 FDR<5%



 Les Exosomes présentent des profils plus spécifiques (IncRNA)



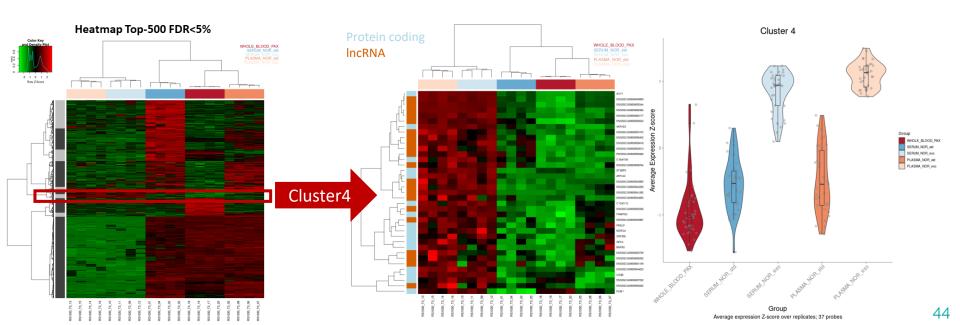




Résultats : Exploration biostatistique : Analyse différentielle

- Décryptage de chaque cluster et des gènes différentiellement exprimés associés :
 - Gènes uniques à un compartiment
 - Gènes communs à plusieurs compartiments
 - Intérêt particulier pour les longs ARN non codants et les gènes codants proches ?

Exemple du cluster 4 : spécifique des Exosomes avec 37 gènes



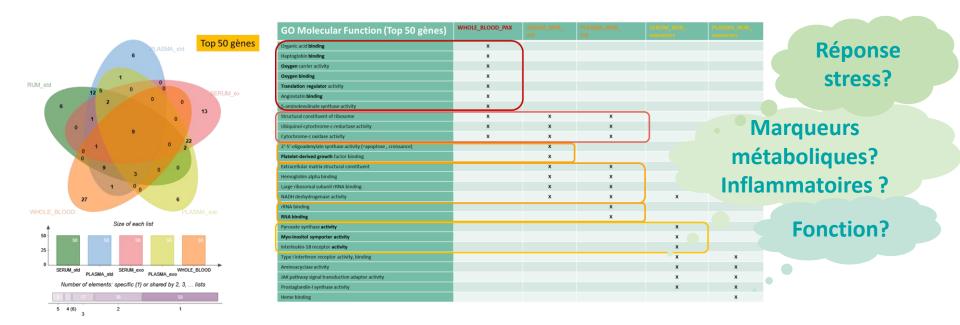






Résultats: Exploration biostatistique: Analyse différentielle

- Exploration des principales fonctions biologiques basée sur l'enrichissement des annotations dans les catégories GO (Biological Process, Cellular Component, Molecular Function), ainsi que dans les bases de données KEGG Pathways et Reactome.
 - 2 approches en parallèle : analyse faite sur l'organisme Sus scrofa (le porc) et Human.



→ Objectif final : Data Paper pour description des données et cartographier les gènes retrouvés dans chaque compartiment et article scientifique en cours de rédaction

INRAO

> Projets 2025 Toxalim

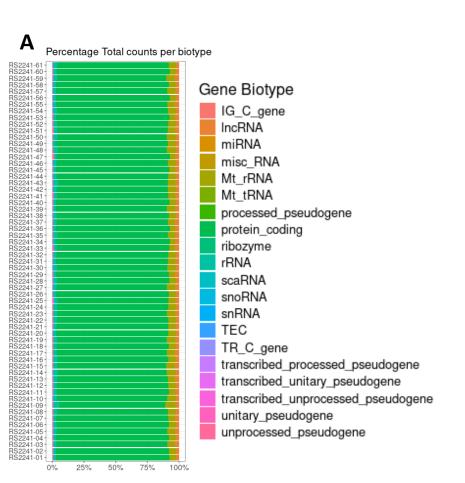


- Foie Souris
- Muqueuse colon Souris
- Muqueuse jéjunum et colon Rat

Liver_Mus_musculus



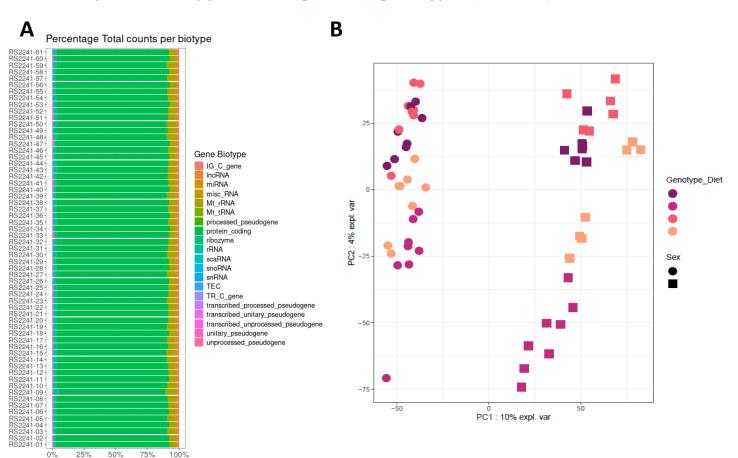
- 61 échantillons : 8 conditions (n=6 à 8), 20 M de reads/éch à la demande de l'équipe.
- (A) 90% des comptages correspondent à des gènes codant pour des protéines (puis ARNr mitochondriaux + long ARN non codants). Détection de 16 000 gènes.



Liver_Mus_musculus



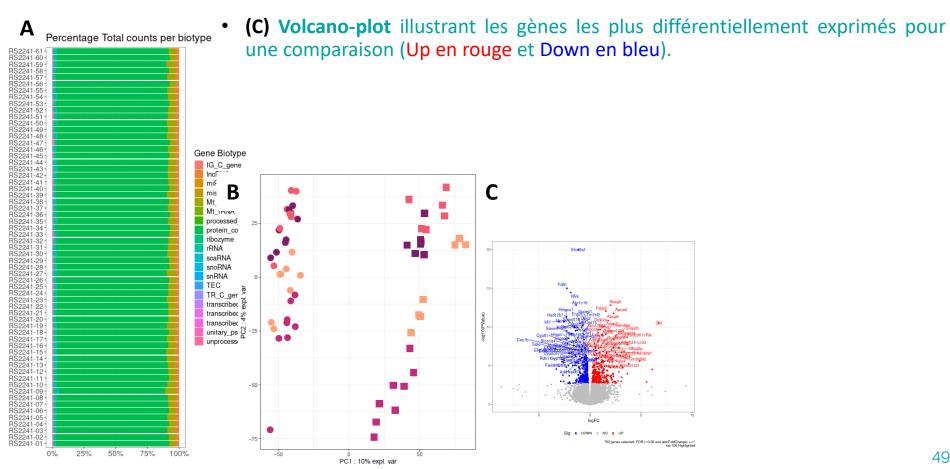
- 61 échantillons : 8 conditions (n=6 à 8), 20 M de reads/éch à la demande de l'équipe.
- (A) 90% des comptages correspondent à des gènes codant pour des protéines (puis ARNr mitochondriaux + long ARN non codants). Détection de 16 000 gènes.
- (B) L'analyse en composante principale (ACP) montre une opposition des sexes (●■) sur la composante 1.
 La composante 2 oppose les régimes et génotypes (● ● ●).



Liver Mus musculus



- 61 échantillons : 8 conditions (n=6 à 8), 20 M de reads/éch à la demande de l'équipe.
- (A) 90% des comptages correspondent à des gènes codant pour des protéines (puis ARNr mitochondriaux + long ARN non codants). Détection de 16 000 gènes.
- (B) L'analyse en composante principale (ACP) montre une opposition des sexes (● ■) sur la composante 1. La composante 2 oppose les régimes et génotypes (• • • •).

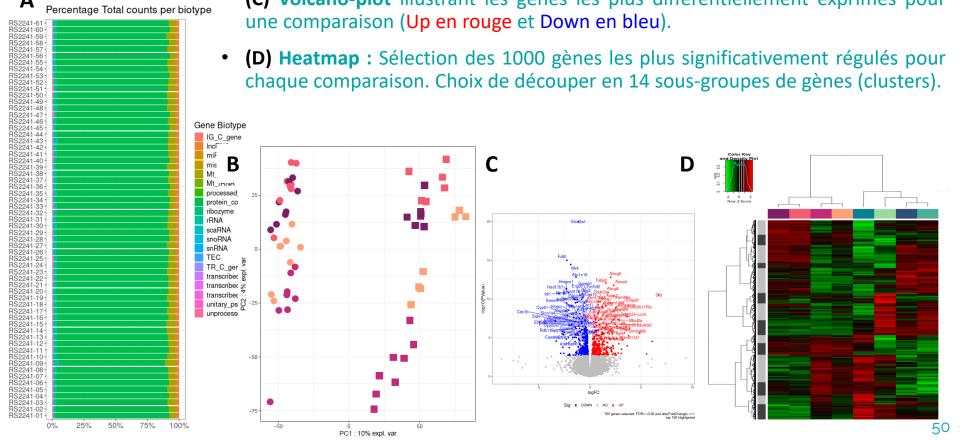


Liver_Mus_musculus



- 61 échantillons : 8 conditions (n=6 à 8), 20 M de reads/éch à la demande de l'équipe.
- (A) 90% des comptages correspondent à des gènes codant pour des protéines (puis ARNr mitochondriaux + long ARN non codants). Détection de 16 000 gènes.
- (B) L'analyse en composante principale (ACP) montre une opposition des sexes (●■) sur la composante 1.
 La composante 2 oppose les régimes et génotypes (● ● ●).

(C) Volcano-plot illustrant les gènes les plus différentiellement exprimés pour





3' mRNA-seq

RNA-seq « classique »

Quantifier l'expression des gènes codants

Analyser l'expression différentielle des gènes (DGE)

Rendu identique des résultats

ARN

ARN: 2 tubes 5 μl à 135 ng/μL

Qualité des ARN: bonne à faible (homogène)

(adaptation du protocole)

Possibilité ARN de sang total (utilisation bloqueur globine)

ARN

ARN: 2 tubes (5 μl et 30 μl) à 100 ng/μl Qualité des ARN: bonne (homogène)

Infos pratiques

3' mRNA-seq

RNA-seq « classique »

Quantifier l'expression des gènes codants Analyser l'expression différentielle des gènes (DGE) Rendu identique des résultats

ARN

ARN: 2 tubes 5 μl à 135 ng/μL

Qualité des ARN: bonne à faible (homogène)

(adaptation du protocole)

Possibilité ARN de sang total (utilisation bloqueur globine)

ARN

ARN: 2 tubes (5 μl et 30 μl) à 100 ng/μl Qualité des ARN: bonne (homogène)



Coût dépend du nombre d'échantillons et de la profondeur de séquençage (taille des flowcells du séquenceur)



Estimation QC ARN + librairies + analyses

Pour 96 échantillons : 75 euros/éch

Pour 96 échantillons (sang) : 90 euros/éch

Pour 96 échantillons : 90 euros/éch

Estimation séquençage

Pour 48 échantillons : ≈ 8 M lectures 35 euros/éch

Pour 96 échantillons : ≈ 12 M lectures 30 euros/éch

Pour 48 échantillons : ≈ 33 M lectures 90 euros/éch Pour 96 échantillons : ≈ 30 M lectures 70 euros/éch

Stockage des données

Pour 1 échantillon : ≈ 0,5 giga octets

Pour 1 échantillon : ≈ 2/3 giga octets

Merci pour votre attention

Personnes impliquées dans les travaux présentés











Equipe REGLISS
Laurence Liaubet
Laure Gress
Maëlle Gusmini

Plateau Génome Transcriptome de Bordeaux Erwan Guichoux Zoé Compagnie Plateau Génomique et Trancriptomique, UMR Inserm Carine Valle Emeline Sarot

BioToMyc, Pinton Philippe



Genotoul Plateforme GeT-TRIX
Claire Naylies
Kory Jason
Yannick Lippi

